Universidad CENFOTEC
Técnico en Data Engineer
SINF-633 Análisis Exploratorio de Datos

Proyecto Final**:**

Implementación completa del modelo KDD para detección de fraude bancario

Profesor: Alexander Arce Quirós

Estudiante: Sylvia Castrillo Urcuyo

Noviembre 2026

Índice

Detección de fraude bancario mediante el modelo KDD..... 2

1. Resumen ejecutivo..... 2
2. Datos y metodología..... 2
3. Resultados cuantitativos..... 3
4. Visualizaciones clave..... 5
5. Interpretación y recomendaciones..... 5
6. Limitaciones y próximos pasos..... 6

Detección de fraude bancario mediante el modelo KDD

1. Resumen ejecutivo

Este proyecto tiene como objetivo identificar patrones que ayuden a diferenciar transacciones bancarias legítimas de fraudulentas y evaluar modelos que puedan servir como apoyo para la prevención de fraude. Para desarrollar el análisis se utilizaron las cinco etapas del modelo Knowledge Discovery in Databases (KDD): selección, preprocesamiento, transformación, minería de datos e interpretación. El conjunto de datos contiene 5.000 transacciones bancarias y 11 variables relacionadas con características del cliente, monto, tipo de transacción, canal, región, estado de la operación y presencia o ausencia de fraude. Al inicio del análisis se determinó que la tasa global de fraude era de 2.18%, lo que evidencia un fuerte desbalance entre las clases, ya que la gran mayoría de las transacciones son legítimas.

A lo largo del análisis se encontraron varios patrones importantes. Por ejemplo, las transacciones consideradas outliers por monto presentaron una tasa de fraude de 13.87%, muy por encima del 0.63% observado en las transacciones que no fueron clasificadas como atípicas. También se observó que las operaciones realizadas entre las 00:00 y las 05:59 tenían una tasa de fraude de 6.01%, mientras que en el resto de los horarios esta tasa fue cercana al 0.91%. Los métodos no supervisados también permitieron identificar grupos interesantes. K-Means generó tres clusters, y uno de ellos presentó una tasa de fraude de 37.14%. Por otro lado, DBSCAN identificó 894 transacciones como anomalías, de las cuales 5.70% correspondieron a fraudes reales.

Finalmente, se entrenaron dos modelos supervisados. La Regresión Logística obtuvo un recall de 81.82% y un AUC-ROC de 90.12%, mientras que Random Forest alcanzó un accuracy de 99.30%, una precision de 100% y un F1-score de 81.08%. Estos resultados muestran que existe un balance entre detectar la mayor cantidad posible de fraudes y evitar generar demasiadas falsas alertas.

2. Datos y metodología

El análisis se realizó utilizando un conjunto de 5.000 transacciones y 11 variables. Estas variables se clasificaron según su tipo y utilidad para el problema de fraude.

Las variables id_transaccion e id_cliente se consideraron identificadores, por lo que no se utilizaron directamente como predictores. La variable fecha_hora sí se conservó al inicio, ya que permitió crear nuevas variables relacionadas con el momento en que ocurrió cada transacción. Entre las variables numéricas se incluyeron edad_cliente, antiguedad_cuenta_meses y monto, mientras que tipo_transaccion, canal, region y estado_transaccion fueron tratadas como variables categóricas.

Durante el preprocesamiento se encontraron valores faltantes en edad_cliente, canal y region. Para edad_cliente se utilizó la mediana, que fue de 40 años, ya que es una medida más robusta frente a posibles valores extremos. En el caso de canal y region, los valores faltantes se reemplazaron por la categoría “Desconocido”, para mantener explícita la ausencia de información sin asignar artificialmente una categoría existente.

También se revisaron registros duplicados y no se encontró ninguno. Los outliers se detectaron utilizando el método del rango intercuartílico con k=1.5. Se encontraron 18 outliers en edad_cliente, ninguno en antiguedad_cuenta_meses y 584 en monto. Debido a que los montos extremos mostraron una relación clara con el fraude, se decidió conservarlos. Además, se aplicó la transformación np.log1p() sobre monto, con lo cual la asimetría de la variable bajó de 8.66 a 1.64. Como parte de la ingeniería de atributos se crearon tres variables nuevas: monto_log, hora_dia y es_noche. Las variables categóricas se transformaron mediante One Hot Encoding con drop_first=True, mientras que las numéricas se estandarizaron utilizando StandardScaler. Para evitar data leakage, el escalado se ajustó únicamente con el conjunto de entrenamiento.

Finalmente, los datos se dividieron en 80% entrenamiento y 20% prueba utilizando stratify=y y random_state=42. De esta forma, la proporción de fraude se mantuvo prácticamente igual en ambos conjuntos.

3. Resultados cuantitativos

La tasa global de fraude fue de 2.18%, lo que corresponde a 109 transacciones fraudulentas de un total de 5.000. Uno de los resultados más claros apareció al analizar los outliers de monto. Las transacciones no atípicas tuvieron una tasa de fraude de aproximadamente 0.63%, mientras que las transacciones consideradas outliers alcanzaron una tasa de 13.87%. Esto muestra que los montos extremos están fuertemente relacionados con una mayor probabilidad de fraude dentro de este conjunto de datos.

El horario también mostró diferencias importantes. Las transacciones realizadas durante la noche presentaron una tasa de fraude de 6.01%, mientras que las realizadas fuera de ese horario tuvieron una tasa cercana al 0.91%.

En K-Means se probaron valores de k entre 2 y 10 utilizando el método del codo y el coeficiente de silueta. Se seleccionó k=3, ya que presentó el mejor valor de silueta, cercano a 0.263. Los tres clusters obtenidos mostraron tasas de fraude de 3.48%, 0.91% y 37.14%. El tercer cluster fue especialmente interesante porque concentró 26 fraudes dentro de apenas 70 transacciones.

DBSCAN, utilizando eps=1.5 y min_samples=10, identificó 894 anomalías. De estas, 51 correspondieron a fraudes reales, lo que equivale a una tasa de fraude de 5.70% dentro de las anomalías.

En el análisis PCA, las primeras dos componentes explicaron aproximadamente 41.68% de la varianza total, mientras que tres componentes alcanzaron 54.29%.

Los resultados de los modelos supervisados fueron los siguientes:

Métrica	Regresión Logística	Random Forest
Accuracy	84.30%	99.30%
Precision	10.53%	100.00%
Recall	81.82%	68.18%
F1-score	18.65%	81.08%
AUC-ROC	90.12%	88.08%

La Regresión Logística detectó 18 de los 22 fraudes reales del conjunto de prueba y dejó pasar 4. Sin embargo, generó 153 falsos positivos. Random Forest detectó 15 fraudes, dejó pasar 7 y no generó falsos positivos.

4. Visualizaciones clave

Las matrices de confusión ayudan a ver con claridad la diferencia entre ambos modelos. La Regresión Logística logra detectar más fraudes, pero también genera una cantidad

importante de falsas alertas. Random Forest, por su parte, es mucho más conservador y prácticamente no genera falsas alarmas, aunque deja pasar más fraudes. Las curvas ROC muestran que ambos modelos tienen una buena capacidad para diferenciar entre transacciones legítimas y fraudulentas. La Regresión Logística obtuvo un AUC-ROC de 0.901, ligeramente superior al 0.881 de Random Forest. La representación mediante PCA también permitió visualizar cómo K-Means separó distintos perfiles de transacciones. Uno de esos grupos aparece claramente diferenciado y coincide con el cluster que presentó la mayor tasa de fraude. Por último, el análisis de importancia de variables del Random Forest mostró que monto y monto_log fueron las variables más relevantes, seguidas por hora_dia, antiguedad_cuenta_meses, edad_cliente y es_noche.

Figura 1: Clusters K-Means

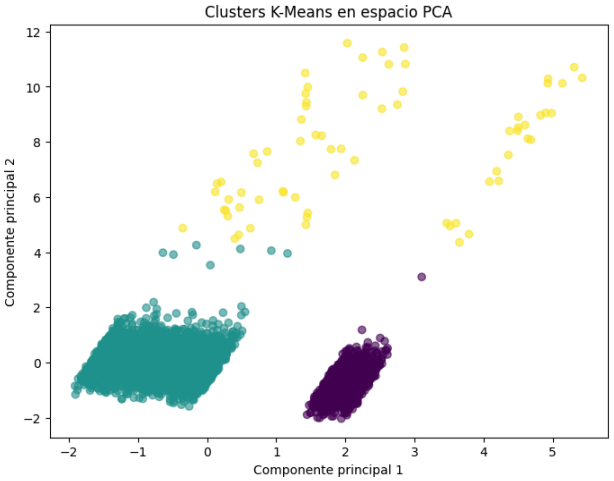


Figura 2: Fraude Real

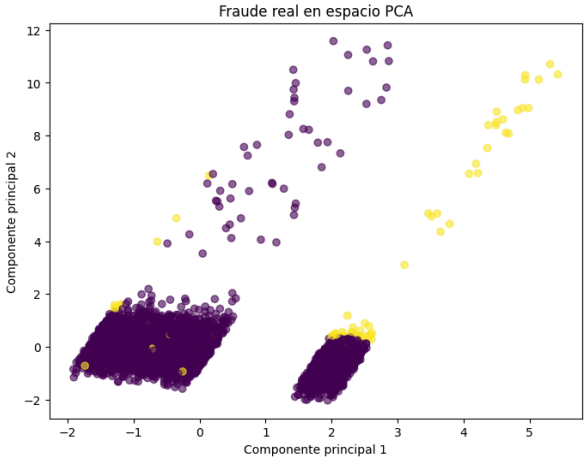


Figura 3: Matriz de confusion: Regresion Logistica

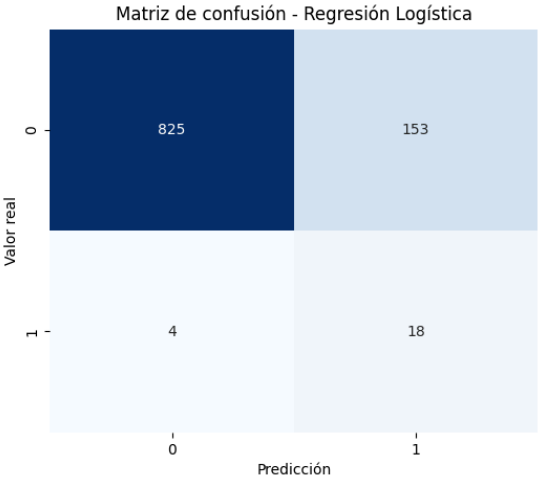


Figura 4: Matriz de confusion: Random Forest

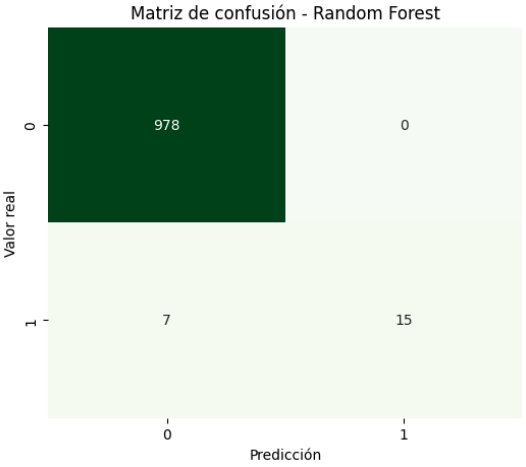
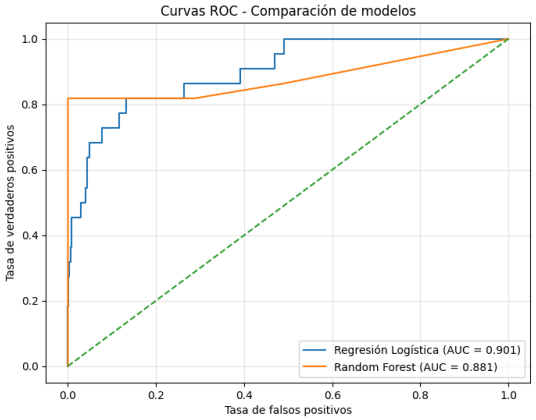


Figura 5: Curvas ROC



5. Interpretación y recomendaciones

Los resultados muestran que el fraude no aparece de forma completamente aleatoria. Existen ciertos patrones que ayudan a identificar transacciones con un nivel de riesgo mayor, especialmente en relación con el monto y el horario.

Los outliers de monto presentan una tasa de fraude mucho mayor que el promedio, por lo que este tipo de operaciones debería recibir una revisión adicional. De forma similar, las transacciones realizadas durante la noche muestran una mayor incidencia de fraude y podrían utilizarse como una señal adicional dentro de un sistema de monitoreo.

Los resultados de K-Means también sugieren que existen perfiles transaccionales con niveles de riesgo muy diferentes. El cluster con una tasa de fraude de 37.14% podría utilizarse como referencia para priorizar ciertas operaciones o aplicar controles adicionales.

En cuanto a los modelos supervisados, la Regresión Logística tiene la ventaja de detectar una mayor proporción de fraudes reales, aunque genera muchas falsas alertas. Random Forest, en cambio, reduce considerablemente esas falsas alertas, pero deja pasar más fraudes.

Por esta razón, no sería recomendable elegir un modelo únicamente por su accuracy. En un contexto bancario, probablemente sea más importante reducir los falsos negativos, ya que representan fraudes que podrían pasar como transacciones legítimas.

Una opción práctica sería utilizar las probabilidades generadas por los modelos para clasificar las transacciones en distintos niveles de riesgo. Por ejemplo, las operaciones de riesgo alto podrían enviarse a revisión o requerir una validación adicional, mientras que las de riesgo bajo podrían procesarse normalmente para evitar afectar innecesariamente la experiencia del cliente.

También sería conveniente probar diferentes umbrales de clasificación para encontrar un mejor equilibrio entre recall y precision.

6. Limitaciones y próximos pasos

Una de las principales limitaciones del análisis es el desbalance de clases. Aunque este tipo de situación es común en problemas de fraude, la cantidad de casos fraudulentos es

relativamente pequeña en comparación con las transacciones legítimas, lo que puede dificultar el entrenamiento y la evaluación de los modelos.

También es importante considerar que los resultados se obtuvieron a partir de un conjunto específico de 5.000 transacciones. Para confirmar que los patrones encontrados se mantienen, sería recomendable probar los modelos con nuevos periodos y con un mayor volumen de información.

En el caso de PCA, las dos primeras componentes explican alrededor de 41.68% de la varianza, por lo que los gráficos en dos dimensiones no representan toda la información disponible y deben verse como una simplificación.

DBSCAN también puede verse afectado por la selección de sus parámetros. Cambios en eps o min_samples podrían modificar la cantidad de transacciones que el algoritmo considera anómalas.

Como próximos pasos, sería conveniente utilizar validación cruzada, probar otros valores de hiperparámetros, analizar diferentes umbrales de clasificación y evaluar los modelos con nuevos datos. También se podrían incorporar otros algoritmos o técnicas enfocadas específicamente en clases desbalanceadas.

A nivel operativo, los modelos deberían monitorearse y actualizarse con frecuencia, ya que los patrones de fraude pueden cambiar con el tiempo. El objetivo no sería solamente detectar la mayor cantidad posible de fraudes, sino hacerlo sin generar una cantidad excesiva de falsas alertas que afecten a los clientes legítimos.